# hadoop configuration

关于 hadoop 的配置笔记

# 屈庆磊

quqinglei@icloud.com

# 2013年7月

# 目录

1	环境变量	2
2	配置 JAVA 环境	2
	2.1 配置 JAVA_HOME	2
3	Hadoop 安装包	2
4	Hadoop 集群安装实例	2
	4.1 说明	2
	4.2 第二步,配置 hosts	2
	4.3 第三步, 配置 JAVA_HOME 见上述章节	3
	4.4 第四步,建立新用户,并解压安装包	3
	4.5 第四步, 配置 ssh 无密码访问	3
	4.6 第五步, 更改 Hadoop 配置文件	4
	4.7 第六步, 把 hadoop 打包, 复制到其他两台机器	5
	4.8 完毕	
5	编译 Hadoop 的 FUSE 模块,机器一定要能上网	5
	5.1 编译前的软件依赖安装	5
	5.2 下载 ant 包, 编译需要它	6
	5.3 设置环境变量	6
	5.3.1 更新环境变量	6
	5.3.2 编译 HDFS	6
	5.4 编译 fuse_dfs	6

1	环境变量	2
6	6 编译并执行经典的例子程序 WordCount	7
	6.1 例子代码	. 7
	6.2 编译过程	. 8

# 1 环境变量

本例中采用和很多环境变量,如: JAVA\_HOME HADOOP\_HOME 等等,建议在做以下工作的时候,先找一个文本文件,把环境变量都写好,然后在写入/etc/profile 文件,当然有些环境变量只是在编译的时候使用,这个你可以根据情况酌情处理,当然环境变量都导出来也是没有什么问题的。

# 2 配置 JAVA 环境

# 2.1 配置 JAVA\_HOME

需要根据系统位数下载不同的安装包,如:32 位的 jdk-7u25-linux-i586.gz,或者 64 位的 jdk-7u25-linux-x64.tar.gz 建议去甲骨文官网下载。

#### 例子:

```
tar xzv jdk-7u25-linux-i586.gz -C /opt
cd /opt
ln -s jdk1.7.0_25 jdk
echo "export JAVA_HOME=/opt/jdk" >> /etc/profile
source /etc/profile
```

# 3 Hadoop 安装包

由于在 Linux 下有很多安装方式,为了统一,本次采用解压包介绍。 去 Hadoop 的官网,找到 Hadoop 的下载地址,在稳定版本里挑一个下载,本例中采用的包为:hadoop-1.1.2.tar.gz

# 4 Hadoop 集群安装实例

本例中有三台机器参与,一台 master,两台 slave,配置比较简单

#### 4.1 说明

192.168.1.5 此台机器作为 master

192.168.1.6 此台机器作为 slave01

192.168.1.7 此台机器作为 slave02

## 4.2 第二步,配置 hosts

配置 Hosts: 编辑 master 机器的/etc/hosts 文件,添加内容为如下所示:

192.168.1.5 master 192.168.1.6 slave01 192.168.1.7 slave02

同步此配置文件到其它两台机器、保持一致即可。

## 4.3 第三步,配置 JAVA\_HOME 见上述章节

# 4.4 第四步,建立新用户,并解压安装包

```
useradd -m hadoop
passwd hadoop # 设置密码
su hadoop
cd /home/hadoop
tar xzf hadoop-1.1.2.tar.gz
ln -s hadoop-1.1.2 hadoop
#hadoop 的家路径此时为:/home/hadoop/hadoop
```

### 4.5 第四步,配置 ssh 无密码访问

其实就是交换公匙

```
# machine master, 使用 hadoop 用户
ssh-keygen -t dsa -P '' -f ~/.ssh/id_dsa
cat ~/.ssh/id_dsa.pub >> ~/.ssh/authorized_keys
scp ~/.ssh/id_dsa.pub hadoop@192.168.1.6:/home/hadoop/.ssh/authorized_keys_master
scp ~/.ssh/id_dsa.pub hadoop@192.168.1.6:/home/hadoop/.ssh/authorized_keys_master
# slaveO1, 使用 hadoop 用户
ssh-keygen -t dsa -P '' -f ~/.ssh/id_dsa
cat ~/.ssh/id_dsa.pub >> ~/.ssh/authorized_keys
cat ~/.ssh/authorized_keys_master >> ~/.ssh/authorized_keys
scp ~/.ssh/id_dsa.pub hadoop@192.168.1.5:/home/hadoop/.ssh/authorized_keys_slave01
# slaveO2, 使用 hadoop 用户
ssh-keygen -t dsa -P '' -f ~/.ssh/id_dsa
cat ~/.ssh/id_dsa.pub >> ~/.ssh/authorized_keys
cat ~/.ssh/authorized_keys_master >> ~/.ssh/authorized_keys
scp ~/.ssh/id_dsa.pub hadoop@192.168.1.5:/home/hadoop/.ssh/authorized_keys_slave02
# master, 使用 hadoop 用户
cat ~/.ssh/authorized_keys_slave01 >> ~/.ssh/authorized_keys
cat ~/.ssh/authorized_keys_slave02 >> ~/.ssh/authorized_keys
```

注意:在 CentOS 下做的同学需要注意,一定要看看 /.ssh/authorized\_keys 的权限是不是 644,如果不是 644,请 chmod 644 authorized\_keys

# 4.6 第五步,更改 Hadoop 配置文件

```
su hadoop
cd /home/hadoop/conf/
# 需要更改: masters, slaves, hadoop-env.sh, core-site.xml, hdfs-site.xml, mapred-site.xml
   更改结果如下所示:
#masters 文件内容
master
#slaves 文件内容
slave01
slave02
#hadoop-env.sh
# 仅仅需要更改 JAVA_HOME 那一行,更改为 JAVA_HOME 的实际路径,本例中我们采用的 JAVA_HOME 为:
export JAVA_HOME=/opt/jdk
#core-site.xml 文件内容
<?xml version="1.0"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<!-- Put site-specific property overrides in this file. -->
<configuration>
property>
<name>fs.default.name</name>
<value>hdfs://master:9000</value>
</property>
</configuration>
#hdfs-site.xml 文件内容
<?xml version="1.0"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<!-- Put site-specific property overrides in this file. -->
<configuration>
property>
<name>dfs.name.dir</name>
<value>/home/hadoop/hadoopfs/name1,/home/hadoop/hadoopfs/name2</value>
property>
<name>dfs.data.dir</name>
```

```
<value>/home/hadoop/hadoopfs/data1,/home/hadoop/hadoopfs/data2</value>
property>
<name>dfs.replication</name>
<value>2</value>
</configuration>
#mapred-site.xml 文件内容
<?xml version="1.0"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<!-- Put site-specific property overrides in this file. -->
<configuration>
property>
<name>mapred.job.tracker</name>
<value>master:9200</value>
</property>
</configuration>
```

# 4.7 第六步,把 hadoop 打包,复制到其他两台机器

在配置完一台机器后,直接可以把配置好的 hadoop 复制到其他机器上,当然在其他的机器上的位置应该是一样的

### 4.8 完毕

基本配置完毕,在主机的/home/hadoop/hadoop/bin 下执行: ./hadoop fs namenode -format 格式化文件系统,然后就可以启动 hadoop 集群了,./start-all.sh 即可启动 hadoop 集群

```
cd /home/hadoop/hadoop
./hadoop fs namenode -format
./start-all.sh
```

如果成功,我们可以在其他机器上都能看到 hadoop 的进程,并且在/home/hadoop/ 会看到/home/hadoop/hadoopfs 的路径出现。

# 5 编译 Hadoop 的 FUSE 模块,机器一定要能上网

如果想在其他机器上挂载 HDFS,则需要编译 fuse dfs 模块

### 5.1 编译前的软件依赖安装

# 如果系统是基于 Redhat 的,请使用 yum 安装,如果基于 debian,使用 apt-get 安装,具体如下: yum install install automake autoconf m4 libtool pkgconfig fuse fuse-devel fuse-libs apt-get install automake autoconf m4 libtool libextutils-pkgconfig-perl \
 fuse libfuse-dev lrzsz build-essential

### 5.2 下载 ant 包,编译需要它

```
tar xzf apache-ant-1.9.1-bin.tar.gz -C /opt
cd /opt
ln -s apache-ant-1.9.1 ant
```

#### 5.3 设置环境变量

把下面环境变量写到/etc/profile 文件里

### 5.3.1 更新环境变量

source /etc/profile

#### 5.3.2 编译 HDFS

```
cd /home/hadoop/hadoop # 进入 hadoop 的家路径 ant compile-c++-libhdfs -Dlibhdfs=1 -Dcompile.c++=1 # 编译 libhdfs, 机器一定要能上网,否则无法编译
```

### 5.4 编译 fuse dfs

```
# 进入 hadoop 家路径,执行 ln -s c++/Linux-$0S_ARCH-$0S_BIT/lib build/libhdfs ant compile-contrib -Dlibhdfs=1 -Dfusedfs=1
```

如果以上不出错,则说明问题解决编译完成后挂载就很简单了,但应该注意以下问题:

- (1) 编辑/etc/ld.so.conf 添加 libhdfs.so 文件的路径,或者可以直接把: /home/hadoop/hadoop/c++/Linux-i386-32/lib/ 里的所有文件拷贝到/usr/lib 路径,记得执行 ldconfig
- (2) 可以把/home/hadoop/build/contrib/fuse-dfs 路径里的两个文件拷贝到/usr/local/bin/ 但必须更改fuse\_dfs\_wrapper.sh 的最后一行./fuse\_dfs 为: /usr/local/bin/fuse\_dfs, fuse\_dfs\_wrapper.sh 是个脚本,请给予执行权限,并可以更改里面的环境变量为真正的值,如果环境变量已设为全局,则不需要更改。

# 6 编译并执行经典的例子程序 WordCount

#### 6.1 例子代码

此例子是经过改动的,如果直接使用 Hadoop 官网的例子在新版本的 Hadoop 1.1.2 会出错,改动处有标记。

```
// WordCount.java
package org.myorg;
import java.io.IOException;
import java.util.*;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.conf.*;
import org.apache.hadoop.io.*;
import org.apache.hadoop.mapreduce.*;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.input.TextInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
import org.apache.hadoop.mapreduce.lib.output.TextOutputFormat;
public class WordCount {
        public static class Map extends Mapper<LongWritable, Text, Text, IntWritable> {
                private final static IntWritable one = new IntWritable(1);
                private Text word = new Text();
                public void map(LongWritable key, Text value, Context context)
                        throws IOException, InterruptedException {
                                String line = value.toString();
                                StringTokenizer tokenizer = new StringTokenizer(line);
                                while (tokenizer.hasMoreTokens()) {
                                        word.set(tokenizer.nextToken());
                                        context.write(word, one);
                                }
                        }
        }
        public static class Reduce extends Reducer<Text, IntWritable, Text, IntWritable> {
                public void reduce(Text key, Iterable<IntWritable> values, Context context)
                        throws IOException, InterruptedException {
                                int sum = 0;
                                for (IntWritable val : values) {
                                        sum += val.get();
                                }
                                context.write(key, new IntWritable(sum));
                        }
```

```
public static void main(String[] args) throws Exception {
    Configuration conf = new Configuration();

    Job job = new Job(conf, "wordcount");

    job.setOutputKeyClass(Text.class);
    job.setOutputValueClass(IntWritable.class);
    job.setJarByClass(WordCount.class); // 多加了这一行!!!

    job.setMapperClass(Map.class);
    job.setReducerClass(Reduce.class);

    job.setInputFormatClass(TextInputFormat.class);
    job.setOutputFormatClass(TextOutputFormat.class);

    FileInputFormat.addInputPath(job, new Path(args[0]));
    FileOutputFormat.setOutputPath(job, new Path(args[1]));

    job.waitForCompletion(true);
}
```

### 6.2 编译过程

clean:

rm -rf wordcount\_classes/\*

废话少说,直接看 Makefile 和文件列表,我觉得模仿是最好的学习方式

```
# run.sh 内容
#!/bin/bash

hadoop fs -rmr /user/hadoop/output/ # output 路径不能存在,否则执行失败
hadoop jar wordcount.jar org.myorg.WordCount input output
# input output 默认是在/user/hadoop/input /user/hadoop/output
# 如果 input 路径不是这个请写绝对路径

# 编译后的 wordcount_classes 路径:
hadoop@debian:~/testHadoop/wordcount$ tree wordcount_classes/
wordcount_classes/
— org
— myorg
— WordCount$Map.class
— WordCount$Reduce.class
```

2 directories, 3 files

注意:执行 run.sh 时,注意 org.myorg.WordCount 是否和上面的 wordcount\_classes 结构一致!